Monitoreo centralizado de microservicios

Solución centralizada para logs:

Opción recomendada: Grafana Loki con Grafana Dashboard.

Por qué Loki y Grafana:

Loki es un sistema de almacenamiento y consulta de logs diseñado específicamente para ser eficiente en términos de costo y escalabilidad. Es "log-oriented" y compatible con Prometheus, lo que facilita su integración con métricas y alertas.



- Alternativa: Elasticsearch con Kibana (ELK Stack).
 - Elasticsearch permite consultas complejas y análisis avanzado de los logs.
 - Kibana es una herramienta robusta para visualización y paneles interactivos.

Configuración básica para Loki:

1. Instalación:

- usar Helm Charts para implementar Loki en los clústeres EKS.
- usar Promtail o Fluent Bit como agentes recolectores de logs en cada nodo del cluster.

2. Integración con Grafana:

Enlazar Grafana con Loki como fuente de datos

docker run -d --name=loki -p 3100:3100 grafana/loki:latest

Para enviar logs a loki hay que configurar el promtail-config.yaml y correr el comando

docker run -d --name=promtail -v /var/log:/var/log -v \$(pwd)/config:/etc/promtail grafana/promtail:latest -config.file=/etc/promtail/promtail-config.yaml

 Crear dashboards de visualización para logs con filtros personalizables por servicio, nivel de error, timestamp, etc.



Costo y eficiencia:



• Loki:

- Es más ligero y consume menos recursos comparado con Elasticsearch, ya que indexa metadatos, no el contenido completo de los logs.
- Perfecto para equipos que necesitan monitoreo sin un aumento drástico de costos.



ELK Stack:

 Ofrece capacidades avanzadas, pero con mayores costos de almacenamiento y procesamiento.

2. Proceso

a. Recolección de logs desde microservicios:

1. Instalación de agentes:

 Deployar agentes de logs (Promtail, Fluent Bit o Fluentd) en los nodos del clúster.

- Configurar los agentes para leer los logs generados por contenedores en el runtime de Kubernetes (generalmente almacenados en /var/log/containers).
- o Enviar los logs a la solución centralizada (Loki o Elasticsearch).

2. Configuración de etiquetas:

- Añadir etiquetas automáticas a los logs, como:
 - service_name: Nombre del microservicio.
 - namespace: Espacio de nombres del clúster.
 - log_level: Nivel de severidad (info, warning, error).
- Esto facilita la búsqueda y el filtrado en los dashboards.

3. Políticas de retención:

 Configurar políticas para retener logs críticos más tiempo (e.g., errores) y purgar logs menos relevantes (e.g., debug) según el presupuesto disponible.

b. Consulta de fallos en tiempo real:

1. Uso de dashboards:

- Los desarrolladores pueden utilizar Grafana o Kibana para filtrar logs en tiempo real por:
 - Nombre del microservicio.
 - Tipo de error o palabras clave.
 - Intervalos de tiempo específicos.

2. Alertas automatizadas:

- Configurar alertas basadas en patrones de logs:
 - Ejemplo: Detectar errores HTTP 500 o excepciones frecuentes.
- Las alertas se pueden enviar a canales de comunicación como Slack, Teams o email.

3. Acceso seguro:

 Usar IAM roles y autenticación mediante SSO para garantizar que solo los desarrolladores autorizados accedan a los logs.

3. Métricas clave para medir la salud de los microservicios (opcional)

1. Uso de recursos:

- CPU y memoria por contenedor.
- o Tasa de uso de disco (especialmente en servicios que generan muchos logs).

2. Tiempos de respuesta:

- Latencia promedio y máxima por endpoint.
- Distribución de los tiempos de respuesta.

3. Errores:

- Tasa de errores (e.g., porcentaje de errores HTTP 5xx).
- Tasa de logs de nivel error o critical.

4. Disponibilidad:

- Número de instancias activas por microservicio.
- o Tiempos de reinicio de contenedores (indica posibles fallos).

En Resumen

realice este esquema basandome en herramientas ligeras y fácilmente integrables como Loki y Grafana, ideales para startups o equipos con presupuestos limitados. Si el equipo tiene mayores necesidades de análisis y escalabilidad, Elasticsearch y Kibana son opciones robustas, aunque más costosas. El enfoque modular asegura quepodamos escalar la solución fácilmente mientras vaya aumentando la carga o la cantidad de microservicios.